

视界先知——VisionOracle

项目说明书

本地视频事件理解、检索与回放系统

提交内容：可运行项目代码 | 完整运行说明 | AI 模型及来源 | 应用场景及用户价值 | Intel AI PC 本地部署与优化方案 | 真实性能测试结果

报告日期：2026 年 9 月 9 日

性能测试平台：Intel Core i9-14900HX / Intel UHD Graphics / Windows 11

执行摘要

VisionOracle 已实现从视频输入到事件理解、统计、检索和证据回放的完整产品闭环。系统支持上传视频与实时摄像头，采用 YOLO11n、目标跟踪、规则事件引擎和 Qwen2-VL-2B-Instruct 分层协同；关键帧、推理、事件记忆和回放均可保留在本地设备，兼顾可解释性、隐私与 AI PC 适配。

Intel AI PC 上的一次完整测试成功处理 15.042 秒、1280×720、24 FPS 视频，得到 6 个事件和 6 条事件记忆，错误为 0。YOLO11n 通过 OpenVINO FP16 的 intel:gpu 路径运行，61 次检测的中位延迟为 17.067 ms、P95 为 21.945 ms；完整测试真实覆盖比赛要求中的 6 项性能指标。

比赛提交材料一览

比赛要求	对应材料
可运行项目代码与完整运行说明	README.md / requirements*.txt / run.ps1 / demo / src
AI 模型及来源说明	docs/MODELS.md
应用场景及用户价值说明	docs/SCENARIOS_AND_VALUE.md
AI PC 本地部署及优化方案	docs/AI_PC_DEPLOYMENT_AND_OPTIMIZATION.md
性能测试结果与原始证据	docs/PERFORMANCE_TEST.md / docs/performance
千问协助答题证明	docs/evidence/qianwen（部分沟通截图）

端到端耗时（秒）
1,194

模型加载完成后，完整 Pipeline 处理 15.042 秒视频的墙钟时间。

视频处理 FPS
0.3

源视频总帧数除以端到端耗时。

YOLO 平均延迟（ms）
25.17

YOLO11n 在 OpenVINO FP16 路径上的平均单次推理延迟。

运行错误数
0

本次完整 Pipeline 运行记录的错误数量。

项目亮点与实测成果

- 完整链路成功闭环。** 本轮状态为成功，361 个源帧全部处理，自动生成 6 个事件与 6 条可检索事件记忆，Pipeline 错误数为 0。
- Intel GPU 检测链路响应快。** YOLO 的 61 次调用平均 25.165 ms，中位数 17.067 ms，P95 为 21.945 ms，证明轻量检测与 OpenVINO FP16 路径已经稳定接入。
- 比赛指标覆盖充分。** 一次真实测试同时提供 E2E、视频处理 FPS、单模型延迟、Pipeline 吞吐、CPU 和内存 6 项指标，超过“至少 4 项”的要求。
- 结果可追溯。** 环境快照、JSON、CSV、测试摘要和 SHA-256 清单全部保留，重要数值可以回到原始证据核验。
- 优化方向清晰。** 当前 Qwen 在 CPU 上完成 16 次调用，完整链路尚未达到实时；这为后续 VLM 加速与调用去重提供了明确、可量化的改进目标。

一、项目优势与完成度

VisionOracle 面向个人学习复盘、经授权的学习指导、教育研究视频初筛和 AI PC 端侧应用展示，已经形成可直接演示和复现的完整系统。

- **从识别到使用的闭环：** 视频不只被打标签，还会形成客观总结、有效时长扇形图、事件时间线、中文检索和一键回放。
- **双输入一致：** 上传视频与实时摄像头复用同一事件协议、时间轴和结果界面；摄像头停止后保留完整录像。
- **分层协同更可控：** YOLO 提供高频物体证据，跟踪与规则产生候选窗口，Qwen2-VL 只复核关键帧，兼顾效率与语义能力。
- **每项结论可核验：** 正式事件具有明确起止时间、描述和对应视频片段，评委可以直接查看证据。
- **端侧隐私：** 模型准备完成后，核心分析不依赖云端模型 API，原始视频无需上传第三方推理服务。
- **跨硬件适配：** 同一代码支持 CPU、NVIDIA CUDA 与 Intel OpenVINO GPU，设备路径相互独立。
- **工程细节完整：** 已处理模型预热、录像帧率、事件回放、超长事件摘要提示、输入锁定和运行状态恢复等实际产品问题。

二、系统架构



YOLO 只提供人物和物体线索，不把“出现手机”直接等同于“使用手机”。最终事件由跟踪、持续时间规则、关键帧和 VLM 结构化判断共同确认。上传与摄像头共享同一事件协议和回放逻辑。

AI 模型及责任边界

模型	框架与精度	项目职责	来源
YOLO11n	Ultralytics + OpenVINO; FP16	人物与学习场景物体检测	Ultralytics 官方模型/权重
Qwen2-VL-2B-Instruct	PyTorch + Transformers; bfloat16	关键帧语义确认、边界与转 场复核	Qwen / ModelScope 官方 模型

模型来源与边界

YOLO11n 来自 Ultralytics 官方模型与权重资源，项目使用 COCO 预训练权重；Qwen2-VL-2B-Instruct 来自 Qwen Team / Alibaba Cloud，项目通过 ModelScope 或本地目录加载官方指令模型。两者均未进行项目专属微调。系统不调用云端模型 API，首次缺少权重时才需要网络下载。

许可证方面，Qwen2-VL-2B 模型页标注 Apache-2.0；Ultralytics 提供 AGPL-3.0 与 Enterprise 两种许可路径，公开或商业使用前应按实际发布方式核对最新条款。

三、Intel AI PC 本地部署

- 1. 使用 Python 3.11 创建独立环境，安装 requirements-intel.txt。
- 2. 使用 tools/intel/prepare_yolo_openvino.py --device intel:gpu --precision fp16 导出 YOLO OpenVINO IR 并完成指定设备真实推理。
- 3. 提前下载 Qwen2-VL 到本地目录，设置 QWEN_VL_MODEL_PATH，避免现场网络依赖。
- 4. 通过 run.ps1 -CheckOnly 检查依赖和模型路径，再以 -YoloDevice intel:gpu 启动。
- 5. Intel GPU 不可用时明确切换 CPU；NVIDIA 环境继续使用 CUDA 参数，三条设备路径互不混写。

Intel AI PC 测试环境

项目	实际配置
CPU	Intel Core i9-14900HX; 24 核 / 32 线程
GPU	Intel UHD Graphics; YOLO 请求设备 intel:gpu
NPU	本次不声明存在或参与推理
内存	31.71 GiB
操作系统	Windows 11 家庭中文版 10.0.26200, 64 位
电源计划	平衡
Python	3.11.16
框架	PyTorch 2.11.0 / Transformers 5.16.1 / OpenVINO 2026.3.1
YOLO	YOLO11n / OpenVINO / FP16 / intel:gpu
VLM	Qwen2-VL-2B-Instruct / bfloat16 / CPU

测试视频与 Pipeline 参数

参数	数值
测试视频	radio.mp4; SHA-256 d799965a...44f
编码与大小	H.264; 1,373,841 字节
分辨率	1280×720
帧率 / 总帧数 / 时长	24 FPS / 361 帧 / 15.042 秒
分析 FPS / 缓冲 FPS	4.0 / 4.0
关键帧数 / YOLO 阈值	9 / 0.35
完整测量次数	1

四、测试方法与指标口径

本次采用固定 15 秒视频执行一次完整 Pipeline。模型先加载再启动计时，未关闭 VLM，也未减少关键功能。E2E 是从 Pipeline 开始到完整结果返回的墙钟时间；视频处理 FPS 为源帧数除以 E2E；分析吞吐为实际 YOLO 调用数除以 E2E；实时倍速为视频时长除以 E2E。

模型加载时间单独记录：YOLO 0.827 秒，Qwen 3.695 秒。361 ÷ 24 = 15.042 秒，与原始视频时长一致；16 次 VLM 分项调用之和也与总调用数一致。

核心性能结果

指标	结果	口径或判断
End-to-End Latency	1194.002 秒	完整 Pipeline 墙钟时间
视频处理 FPS	0.302 FPS	361 源帧 ÷ E2E
Pipeline 分析吞吐	0.051 帧/秒	61 分析帧 ÷ E2E
实时倍速	0.0126×	未达到实时
每 1 秒视频处理时间	79.380 秒	当前完整功能基线
事件 / 记忆 / 错误	6 / 6 / 0	本轮成功完成

YOLO11n 单模型延迟

统计项	结果
调用次数	61
平均延迟	25.165 毫秒
中位数	17.067 毫秒
P95	21.945 毫秒
最大值	506.493 毫秒

VLM 调用构成

调用阶段	调用次数
主判断	3
位置复核	3
窗口标签	6
转场定位	4

资源占用

指标	平均值	峰值
系统 CPU	73.658%	96.700%
进程 CPU（32 线程归一化）	67.609%	77.441%
进程内存 RSS	5.102 GiB	5.430 GiB

五、数据质量、限制与 NPU 校正

原始结果文件状态为 `success`，错误数为 0，四份证据文件的 SHA-256 与清单一致。原始 JSON 中进程 CPU 超过 2000%，这是 `psutil` 把多个逻辑线程使用率累加后的口径；正文采用 32 线程归一化值，并同时保留系统 CPU 指标。

原始环境快照曾把 `Microsoft Input Configuration Device` 识别为 NPU，原因是旧正则英文 `INPUT` 内误匹配到 NPU。该字段已在报告中排除，采集器也已改为严格边界匹配。Intel 官方说明中 NPU 通常显示为 `Intel AI Boost`；本测试不声明 NPU 存在或参与推理。

结论限制：只有一次短视频运行，不能评价多轮波动或长期稳定性；电源计划为“平衡”；没有可靠 GPU 利用率、显存、功耗、温度或 VLM 单次延迟。这些缺失指标不以 0 代替，也不建立占位章节。

比赛性能要求覆盖

比赛候选指标	本次实测证据
视频处理 FPS	0.302 FPS
End-to-End Latency	1194.002 秒
单模型推理 Latency	YOLO 平均 25.165 ms，中位数 17.067 ms，P95 21.945 ms
视频 Pipeline Throughput	0.051 分析帧/秒
CPU 利用率	系统平均 73.658%，峰值 96.700%
内存占用	平均 5.102 GiB，峰值 5.430 GiB

六、已实现的优化

- **轻量检测与异构执行**：YOLO11n 导出 OpenVINO FP16，在 Intel GPU 路径执行；Qwen 选择 2B 规模。
- **分层采样**：源视频保持 24 FPS 播放和归档，检测与缓冲按 4 FPS，VLM 只处理候选时间窗的 9 张关键帧。
- **模型复用**：页面启动后预热 YOLO、Qwen 与 Processor，上传视频和摄像头复用同一实例。
- **录像与分析解耦**：摄像头按实际采集帧率编码，停止时合并完整 MP4，事件时间轴不由慢速 VLM 决定。
- **本地数据闭环**：关键帧、事件、检索和回放均留在本机，运行数据默认不提交 Git。

优化路线与验收指标

优先级	优化项	验证指标
P0	增加 VLM 分阶段计时	VLM 平均、P50、P95、阶段耗时占比
P0	基于状态与相似度减少重复 VLM 调用	调用数、E2E、事件一致性
P1	验证 Qwen 的 Intel 加速后端	VLM 延迟、内存、准确性回归
P1	增加 Intel GPU 遥测和设备全名	GPU 利用率、显存、设备证据
P1	固定最佳性能模式并进行多轮测试	E2E 极差、变异系数
P2	以代表性校准集评估 YOLO INT8	YOLO 延迟、召回率、事件一致性

七、应用场景与用户价值

VisionOracle 的价值是把难以浏览的长视频整理成可搜索、可统计、可回放的本地事件记忆。学习者可以快速定位阅读、书写、手机或电脑使用等片段；经授权的教师和研究人員可以先查看事件目录，再回到原画面复核；AI PC 展示则体现轻量检测、视觉语言模型、事件引擎与交互式检索在单机上的协同。

系统不替用户评价学习状态。任何涉及他人拍摄、未成年人或教育评价的使用，都应取得知情授权、遵守数据保护要求，并由人工复核模型输出。

八、复现与原始证据

正式测试命令：

```
python tools/performance/run_intel_benchmark.py `
--source "D:\Videos\radio.mp4" `
--qwen-model-path "D:\AIModels\Qwen2-VL-2B-Instruct" `
--yolo-device intel:gpu `
--label intel_ai_pc
```

项目 Git 提交：c608aae52dad81ecdbbee5e7fcda14e6291396054。原始结果位于 docs/performance/intel_ai_pc_20260909_034520/，包含环境快照、JSON 权威数据源、CSV 表格结果、测试摘要和 SHA-256 清单。

千问协助答题说明

项目筹备过程中使用千问协助理解赛题、梳理系统架构、规划团队分工和解读性能测试要求。说明书后附 4 张**部分沟通截图**作为使用证明；截图不是完整对话，最终架构、代码和测试结论均由团队结合实际项目核验。

综合结论

项目已经形成可运行代码、完整运行说明、模型及来源说明、应用场景及用户价值说明、Intel AI PC 本地部署与优化方案以及可追溯的真实性能结果。YOLO Intel GPU 路径已经稳定接入，事件理解、检索和证据回放形成完整闭环；当前性能基线也为下一步 VLM 加速提供了清晰目标。

附录：千问协助答题部分沟通截图（1/2）

以下仅展示项目筹备过程中使用千问协助理解赛题和完善方案的部分沟通截图，并非完整对话记录。最终架构、代码实现、测试数据与提交材料均由团队结合实际项目核验。



部分沟通截图 1 千问协助分析 AI PC 本地视频智能分析赛题要求与开发方向。



部分沟通截图 2 千问协助基于赛题分析梳理整体系统架构。

附录：千问协助答题部分沟通截图（2/2）

截图用于说明千问在需求理解、架构组织、团队协作和性能测试解读中的辅助作用。千问建议经过团队筛选，不能替代真实代码、真实设备测试和人工复核。



部分沟通截图 3 千问协助设计五人团队的模块化分工方案。



部分沟通截图 4 千问协助解读性能测试指标与提交材料组织要求。