



吉林大学
JILIN UNIVERSITY

视界先知——VisionOracle

学习场景下的本地视频事件理解与自然语言检索系统

看得懂正在发生的事情 —— 检测 · 跟踪 · 理解 · 总结 · 溯源

求实创新，励志图强

设计人：于洋，冉新敏，杨潇睿，高嘉沐，王彦如

指导教师：冯莎莎，于海鸿，张永刚

|| 目 录 ||

C O N T E X T

- 1 项目背景与价值
- 2 系统架构与核心流程
- 3 核心模块实现
- 4 部署与性能测试
- 5 亮点创新与总结展望



01

项目背景与价值



传统方式痛点

耗时成本高

- 01 学习视频时长较长、有效信息密度低，人工完整回看耗费大量时间
- 02 完整复盘学习行为，需要人工持续紧盯屏幕观测记录

检索核验难

- 03 查找关键学习事件（如分心、阅读、操作行为），只能手动反复拖动进度条定位
- 04 AI 仅生成文本摘要，无法直接跳转原视频，难以回溯原始画面核验依据

云端方案隐患

- 05 云端视频分析需要上传录像，存在网络依赖、传输耗时与用户隐私泄露风险



定位：学习场景下的本地视频事件理解与自然语言检索系统

角色	核心需求	系统为其提供	达成效果
学习者本人	自主复盘学习过程，快速定位分心、卡顿片段	可核验的学习时间线与原始视频回放	直观掌握自身学习状态，自主发现问题
家长与教师	高效查看学习全过程，完成行为复盘与标注	结构化事件记录，免去全程盯屏观看	降低监督成本，快速定位异常片段
网络教学平台	客观留存课堂行为数据，评估授课质量	隐私友好的本地多模态事件取证	留存课堂证据，辅助核验、保障授课水准



02

系统架构与核心流程



1

交互层 • Gradio Web: 上传视频 / 实时摄像头

2

感知层 • YOLO11n 目标检测 → SimpleTracker 目标跟踪

3

事件层 • EventEngine 规则状态机: 产生候选事件 + 时间窗

4

语义层 • 关键帧抽取 → Qwen2-VL-2B 三步协议确认 (含边界复核)

5

记忆 / 检索层 • 事件记忆 → 时间线 / 客观总结 / 扇形图 / 检索 / 回放

视界先知 VisionOracle

本地视频事件理解与自然语言检索系统



系统亮点

- 视频上传 + 实时摄像头
- YOLO + 跟踪 + 规则 + VLM 联合判断
- 全链路本地推理 · 隐私友好
- 结构化时间线 · 检索 · 回放



系统入口



Gradio Web

图形化界面 · 便捷使用



CLI 命令行

灵活控制 · 脚本执行



EndToEndRunner

统一编排与生命周期管理

1 视频输入与时间轴



上传视频



实时摄像头

VideoFileSource / CameraSource



FrameStream: 统一帧与时间戳

2 实时视觉感知



YOLO11n 目标检测

person · book · phone · laptop...



SimpleTracker 目标跟踪


稳定 track_id

3 候选事件引擎



EventEngine 状态机

位置关系 + 物体线索 + 时序规则



候选事件窗口

入座 / 离座 / 阅读 / 写字
手机 / 电脑 / 交流 / 其他

4 关键帧与语义确认



VideoBuffer

文件关键帧 / 实时证据帧



Qwen2-VL-2B-Instruct

多帧理解 · 边界复核 · 结构化校验



已确认事件

5 事件记忆与检索



MemoryRecord + InMemoryStore



HashingEmbedder

(本地哈希向量)

查询规范化 + 余弦相似度



自然语言搜索结果

6 媒体归档与产品呈现



摄像头分段录像



FFmpeg / OpenCV

回放导出



全事件总结



事件时间线



时长统计



事件回放



视频帧



检测结果



跟踪结果



候选事件



关键帧 + 时序证据



VLM 确认



事件记忆 / 展示回放



本地数据与模型



本地模型

models/yolo11n.pt

Qwen2-VL 模型目录 / ModelScope 首次下载



运行数据 data/

clips · recordings · replays · previews · outputs



视频默认不上传第三方推理服务

所有推理与数据均在本地完成, 保护您的隐私

03

核心模块实现



核心技术① —— YOLO11n + 目标跟踪：轻量高频的物体线索

- 模型：Ultralytics YOLO11n, COCO 预训练, 约 2.6M 参数 / 5.35 MiB (float32)
- 保留 8 类目标：person / chair / dining table / book / cell phone / laptop / keyboard / mouse
- YOLO11n 对采样帧执行目标检测，输出目标类别、置信度和边界框

YOLO 检测示意 · 非真实截图



目标跟踪模块采用轻量级匹配算法：

- 首先按目标类别筛选候选轨迹。
- 然后综合边界框 IoU 和中心点距离完成帧间匹配。
- 匹配成功后沿用原 Track ID。
- 短时漏检时保留轨迹，连续多帧丢失后再删除。

✓ 设计要点：只给“物体证据”，不给“行为结论”

例：手机出现 ≠ 使用手机

行为结论交给下游规则与多模态确认。

源码：src/detection/detector.py · src/tracking/



对外事件词表 · 中文名 + 代码字段

事件	字段	事件	字段
坐到学习位置	sit_at_study_position	使用手机	phone_usage
离开学习位置	leave_study_position	使用电脑	computer_usage
阅读	reading	交流分心	communication_distraction
书写	writing	其他	other_behavior

✔ 对外只有这 8 类：学习开始 / 结束只是内部状态，不对外展示

⌚ 候选事件是弱候选：规则引擎只产生候选 + 时间窗，最终交由 VLM

检测到书本

表示当前窗口可能包含阅读行为。

检测到手机

表示画面中出现手机，不直接认定用户正在使用手机。

检测到电脑、键盘或鼠标

表示当前窗口可能包含电脑操作。

多种物体同时出现

系统保留全部候选及其出现比例。



核心技术③ —— Qwen2-VL 三步协议：让 2B 模型不幻觉



吉林大学
JILIN UNIVERSITY

1

objective_description —— 描述可见事实

只描述核心动作与先后， ≤ 40 字，禁止外貌 / 颜色 / 背景幻觉

2

events / event_labels —— 选择事件标签

从八类中结构化判断实际发生的事件（布尔值）

3

activity_segments + final_description —— 复核时间边界

有动作变化时按帧号分段，再生成受约束的最终描述



稳定性： 关闭随机采样，所有调用复用同一模型与 Processor。



解析失败走确定性兜底， 不反向制造事件

输入：候选事件关键帧

关键帧 1（含 person + cell phone）

关键帧 2（人物低头、手部在桌面上方）

时序证据：手机出现 12~88 帧



输出：受约束 JSON（协议输出示例）

```
{"objective_description": "学生坐到桌前，拿起手机查看"}  
{"events": {"phone_usage": true, "reading": false}}  
{"activity_segments": [{"start": 12, "end": 88}]}  
{"final_description": "使用手机约 76 帧，随后放回"}
```




核心技术④ —— 把结论变成可查、可回放的记忆



吉林大学
JILIN UNIVERSITY



客观总结

按已确认事件顺序生成确定性过程描述



有效时长扇形图

只统计已确认事件有效时长，按占比排序

合并同类型且真正相邻的事件窗口，起止时间对齐

事件时间线



点击事件即可展示弹窗回放。

事件不超过 60 秒时导出完整片段，事件较长时提取开头、中间和结尾生成摘要回放。

每个确认事件都会转换为一条结构化视频记忆，主要包含：

- 事件类型与事件编号
- 开始时间和结束时间
- 目标 Track ID 与置信度
- Qwen2-VL 生成的事件描述
- 关键帧路径与视频回放路径
- 检索向量和语义分析元数据



自然语言中是否能识别出具体事件（事件词典）

是

系统就直接映射到对应事件类别，并在该类别的记录中进行检索

否

自然语言检索采用“**事件词典匹配 + 向量相似度排序**”的组合方式。

系统先识别问题中的事件表达，例如“看手机”“什么时候读书”和“离开座位”，并映射到统一事件类型。随后对查询文本和事件描述生成向量，在同类型事件中计算余弦相似度，返回最相关的时间片段。

用户点击搜索结果或事件时间线后，可以直接播放对应视频证据。事件不超过 60 秒时导出完整片段，事件较长时提取开头、中间和结尾生成摘要回放。上传视频的回放会尽量保留原始音频。



demo截图演示 —— 上传视频，生成事件时间线与全事件总结



✦

视界先知——VisionOracle

从视频事件到可检索的学习行为记忆

Qwen2-VL · Local Intelligence

INPUT

视频输入

上传本地视频，或切换到实时摄像头。

上传视频

实时摄像头

Video

开始分析

停止

恢复最近结果

正在加载模型

OVERVIEW

全事件总结

按照已确认事件及其时间顺序生成客观过程描述。

视频中，人物依次坐到学习位置、阅读、使用手机、使用电脑和书写；过程中还包含学习准备、整理或动作切换。

有效总时长
2分8.33秒

使用电脑

24.9%

32.01秒

写字

22.6%

29.01秒

阅读

21.8%

28.01秒

使用手机

18.7%

24.01秒

其他

10.3%

13.17秒

坐到学习位置

1.7%

2.13秒

TIMELINE

具体事件时间线

点击事件即可打开对应回放。

其他

0秒 – 1.07秒

该时段未检测到可确认的学习动作。

坐到学习位置

1.07秒 – 3.2秒

人物走近学习位置并坐下。

其他

3.2秒 – 7.2秒

人物正在拿取、摆放或整理书本和学习用品。

阅读

7.2秒 – 35.21秒

人物持续注视书页进行阅读。

使用手机

35.21秒 – 59.22秒

人物持续注视或操作手机。

使用电脑

59.22秒 – 1分31.22秒

人物持续注视或操作电脑。

其他

1分31.22秒 – 1分34.23秒

人物处于学习准备、整理或动作切换阶段。

写字

1分34.23秒 – 2分3.23秒

人物持笔在纸面持续书写。

其他

2分3.23秒 – 2分8.33秒

人物处于学习准备、整理或动作切换阶段。

注解：左侧是原始视频，右侧是分析结果，两者时间对齐、可点击回放；时间线每一段都来自已确认事件，可溯源。



demo截图演示 —— 自然语言搜索，一键定位与回放



吉林大学
JILIN UNIVERSITY

SEARCH

自然语言搜索

例如：什么时候阅读了？

阅读

搜索

本次视频中发生 1 个“阅读”事件。

阅读

7.2秒 – 35.21秒

人物持续注视书页进行阅读。

点击事件 → 原视频片段

播放

保留原视频音频
事件证据可回到原始画面核实

从一句自然语言，到原始画面的视频
证据，两步点完。

事件回放

当前选中事件的完整视频片段


关闭





规则与模型协作

不让 YOLO 或 VLM 单独拍板，检测 / 规则 / 多模态三者交叉确认



输入方式一致

上传视频与摄像头共用同一套事件协议和界面

事件证据闭环

摘要、图表、搜索最终都能落到原视频回放

本地优先

不依赖收费多模态 API，原始视频不外发

04

部署与性能测试



性能测试 —— 方法与环境 (测试说明项)

硬件环境 • collect_environment 实测

项目	实测值
CPU	Intel Core i9-14900HX (24 核 / 32 线程)
GPU	Intel UHD + NVIDIA RTX 4060 Laptop GPU
NPU	无 (本轮未使用 NPU)
内存	32 GB
系统	Windows 11 (10.0.26200)

软件 / 框架

Python 3.11.16 · PyTorch 2.11.0
Transformers 5.16.1 · Ultralytics 8.4.140
Gradio 6.26.0 · OpenCV 5.0.0 · OpenVINO 2026.3.1

模型与精度

YOLO11n (OpenVINO FP16, intel:gpu)
Qwen2-VL-2B-Instruct (bfloat16, CPU)

测试视频

1280 × 720 @ 24 fps, 15.042 秒
H.264 · 361 帧 · 完整事件分析视频

完整 Pipeline 实测: YOLO 使用 OpenVINO FP16; Qwen2-VL 在 CPU 上运行; 本轮未使用 NPU。




性能测试 —— 完整 Pipeline 核心指标实测

指标	实测结果
① End-to-End 延迟	1194.002 s (约 19 分 54 秒)
② 视频处理 FPS	0.302 FPS · 分析吞吐 0.051 帧/s
③ YOLO 单模型延迟	mean 25.165 ms · median 17.067 ms · P95 21.945 ms
④ 资源利用率	CPU 均值 73.658% / 峰值 96.700% · 内存峰值 5.430 GiB

- ① 模型加载完成后，对完整视频 Pipeline 计时 1 次
- ② 361 个源帧 ÷ 1194.002 s
- ③ YOLO 共调用 61 次，独立记录延迟分布
- ④ 资源采样 2276 次，间隔 0.5 s

YOLO 单模型延迟 (ms)



61 次调用：中位数 17.067 ms, P95 21.945 ms

完整运行生成 6 个事件和 6 条记忆，错误数为 0。

YOLO 使用 OpenVINO FP16; Qwen2-VL 在 CPU 上运行，完整系统尚未达到实时。



完整 Pipeline 结果与优化方向



吉林大学
JILIN UNIVERSITY

完整 Pipeline 实测

19 分 54 秒

15.042 秒视频 E2E (模型加载后计时)

视频处理速度 0.302 FPS, 分析吞吐

0.051 帧/s

YOLO 平均 25.165 ms; 主要耗时来自

CPU 上的 VLM 调用

下一步优化与验证

1 • 优先加速 VLM: 迁移到 GPU, 并减少不必要的复核调用

2 • 保持 YOLO 的 OpenVINO FP16 路径, 继续优化采样与预热

3 • 增加 VLM 分阶段计时, 并用同一视频重复测试验证波动

结论: 完整 Pipeline 已成功运行, 事件输出与记忆写入均无错误。

当前 E2E 尚未达到实时, 下一步重点优化 Qwen2-VL, 并以相同视频和参数复测。



05

亮点创新与总结展望



工程实践与创新点



职责清晰：检测 / 跟踪 / 事件 / 语义 / 记忆分层，模块边界明确



冷启动预热：页面打开即预热模型，就绪后才可开始，交互不卡顿



复用同一模型：Qwen 各类复核（主判断 / 边界 / 位置 / 转场）复用同一份权重，进程级缓存



输入统一：摄像头与文件共用 VideoFrame / VideoSource 接口



健壮性：视频帧读取重试、JSON 解析多级容错、契约校验 (normalize_vlm_result)



证据可追溯：被拒绝事件写 debug 日志，不静默丢弃

工程细节：

模块边界、容错路径、日志留痕、预热策略、接口统一 —— 每个点都能在 src/ 目录找到对应实现。




边界、伦理与隐私（合规加分）



吉林大学
JILIN UNIVERSITY

回答“什么时候发生了什么事、持续多久、占比多少、能否回看核实”；
不推断态度、能力、身份，不做排名或打分。
这决定了系统在隐私与伦理上可以保持克制。



01.知情同意

录制与使用前明确告知，授权范围内使用

02.数据最小化

不采集摄像头音频，只处理行为相关的视频帧

03.本地优先

分析在本地完成，原始视频不外发、不依赖云端 API

04.可删除

视频与事件数据可随时删除，不留残留

05.人工复核

关键事件可复核

06.限制访问

结果仅授权者可见



1 • 多用户权限与审计

角色化访问控制，操作留痕可审计，覆盖授权使用场景

2 • 事件人工编辑与导出

人工修正事件边界，导出结构化数据供下游研究使用

3 • 跨视频事件检索

更大规模语料上统一检索，支持跨视频行为模式对比

4 • 异构后端与量化

INT4 量化与更多异构后端，把VLM 环节压到可用时延

5 • 真实场景评测集

面向学习场景构建标注评测集，量化事件识别准确率

从“能跑通”走向“能审计、能规模化、能量化评测”。



吉林大学
JILIN UNIVERSITY

视界先知——VisionOracle

学习场景下的本地视频事件理解与自然语言检索系统

—— 求实创新，励志图强 ——

感谢各位聆听，恳请各位批评指正